

## Parte 1 (12 valores)

Nome \_\_\_\_\_

Número \_\_\_\_\_ Curso \_\_\_\_\_

1. Seja  $\mathcal{A} = \mathbb{R}^3$  o espaço de admissível para eventos numa base de dados. Considere a função dissimilaridade entre 2 eventos  $x, y \in \mathcal{A}$  definida da seguinte forma,

$$d(x, y) = \frac{1}{3} \sum_{i=1}^3 d_i(x, y)$$

onde,

$$d_i(x, y) = \begin{cases} 1, & \text{se } x_i \neq y_i, \\ 0, & \text{se } x_i = y_i. \end{cases}$$

a) Mostre que é uma função de dissimilaridade.

---

b) Verifique se  $d(x, y)$  goza da propriedade de simetria.

---

c) Verifique se  $d(x, y)$  goza da propriedade da identidade de indiscerníveis ("definitness").

---

d) Uma função de dissimilaridade como esta é apropriada para ser usada num algoritmo de clusterização como o de Lloyd para uma base de dados com eventos  $e \in \mathcal{A}$ ? Justifique.

---

2. Considere o conjunto  $C = \{x^1, x^2, x^3, x^4, x^5, x^6, x^7\}$  onde  $x^1 = (0, 0)^T$ ,  $x^2 = (1, 1)^T$ ,  $x^3 = (0, 1)^T$ ,  $x^4 = (1, 0)^T$ ,  $x^5 = (70, 0)^T$ ,  $x^6 = (0, 2)^T$ ,  $x^7 = (2, 0)^T$ . Nota: os elementos  $x^i \in \mathbb{R}^2$ .

a) Calcule o representante de  $C$  (do tipo centróide), usando a métrica Euclidiana.

---

b) Calcule o representante de  $C$  (do tipo centróide), usando a métrica de Manhattan.

---

c) O que podemos inferir relativamente aos dados de  $C$  tendo em conta os resultados das alíneas anteriores?

---

**3.** Considere que tem uma base de dados composta por eventos que são figuras de 25 pixels binários. Um evento é um vector com 25 componentes binárias. Nessa base de dados há 3 eventos:

$$x = (1, 0, 0, 0, 0, 1, 0, 0, 0, 0, 0, 0, 0, 0, 0, 1, 1, 1, 0, 0, 1, 1, 1, 0, 0),$$

$$y = (1, 0, 0, 0, 0, 1, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 1, 1, 1, 0, 0, 1, 1, 1),$$

$$z = (0, 0, 0, 0, 1, 0, 0, 0, 0, 1, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0).$$

representados abaixo.




Figure 1: Evento  $x$  à esquerda; evento  $y$  no meio; evento  $z$  à direita

a) Calcule a semelhança entre  $x$  e  $y$ , entre  $x$  e  $z$  e entre  $y$  e  $z$  usando uma função de semelhança do tipo "overlap".

b) Calcule a semelhança entre  $x$  e  $y$ , entre  $x$  e  $z$  e entre  $y$  e  $z$  usando uma função de semelhança do tipo Jacard.

c) Atendendo aos resultados obtidos, qual das métricas lhe parece mais apropriada para medir a semelhança das figuras? Justifique.

**4.** Considere que tem uma base de dados  $D = \{x^1, x^2, x^3, x^4, x^5\}$  onde  $x^1 = (0, 0)^T$ ,  $x^2 = (0, 1)^T$ ,  $x^3 = (1, 0)^T$ ,  $x^4 = (10, 10)^T$  e  $x^5 = (8, 10)^T$ .

Vamos supor que se pretende aplicar o algoritmo de Lloyd com  $k = 2$ , usando a métrica euclidiana e representantes do tipo centroide. Para começar a correr o algoritmo considere que os representates iniciais são  $\mathbb{M}(0) = \{(0, 0)^T, (5, 5)^T\}$ . Nota: os elementos  $x^i \in \mathbb{R}^2$ .

Considere ainda que a condição de paragem é os representantes de duas iterações consecutivas serem os mesmos.

a) Apresente os calculos da primeira iteração do algoritmo de Lloyd.

b) Se os representantes iniciais fossem diferentes, obteria a mesma partição final após a convergência do algoritmo de Lloyd? Justifique?