

Métodos de Penalidade

Método de Penalidade Quadrática

M. Fernanda P. Costa

Departamento de Matemática
Universidade do Minho

Outline

- 1 Métodos de Penalidade
 - Método de Penalidade Quadrática

Métodos de Penalidade

Considere a seguinte formulação geral do problema de otimização com restrições:

$$\begin{aligned}
 &\underset{w \in \mathbb{R}^I}{\text{minimizar}} && F(w) \\
 &\text{sujeito a} && c_n(w) = 0, \quad n \in \mathcal{E} \\
 &&& c_n(w) \geq 0, \quad n \in \mathcal{I}
 \end{aligned} \tag{1}$$

- $w = (w_1, w_2, \dots, w_I)^T$ é o vetor das variáveis de decisão
- $F : \mathbb{R}^I \rightarrow \mathbb{R}$ é a função objetivo (medida de desempenho)
(loss or cost function in ML)
- $c_n : \mathbb{R}^I \rightarrow \mathbb{R}$ com $n \in \mathcal{E}$, são as funções de restrição de igualdade
- $c_n : \mathbb{R}^I \rightarrow \mathbb{R}$ com $n \in \mathcal{I}$, são as funções de restrição de desigualdade

- Um classe importante de métodos para resolver problemas de otimização com restrições é os *Métodos de Penalidade*.
- Estes métodos substituem o problema original por uma sucessão de subproblemas sem restrições, adicionado um termo de penalidade, por restrição, à função objetivo. O termo penaliza, ou seja aumenta o valor da função objetivo, sempre que a restrição é violada.
- Vamos aqui apresentar três abordagens:
 - *Método de Penalidade Quadrática*
 - *Métodos de Penalidade Exata Não Suaves*
 - *Método da Lagrangeana Aumentada* (ou *Método dos Multiplicadores*)

Método de Penalidade Quadrática

Motivação

- O problema de otimização com restrições (1) é substituído por uma **função de penalidade**, definida pela:
 - função objetivo do problema original **mais**
 - um termo de penalidade, por restrição, **que é positivo quando o ponto w viola a restrição e zero caso contrário.**
- A maioria das abordagens define uma sucessão de funções de penalidade, em que **os termos de penalidade são multiplicados por um coeficiente positivo μ , chamado *parâmetro de penalidade*.**
- A função de penalidade mais simples deste tipo é a **função de penalidade quadrática**.

Método de Penalidade Quadrática

- Considere o problema com restrições (1).
- Define a seguinte **função de penalidade quadrática** $Q(w; \mu)$, com $\mu > 0$:

$$Q(w; \mu) = \underbrace{F(w)}_{\text{função objetivo}} + \underbrace{\frac{\mu}{2} \sum_{n \in \mathcal{E}} (c_n(w))^2 + \frac{\mu}{2} \sum_{n \in \mathcal{I}} (\max(0, -c_n(w)))^2}_{\text{um termo de penalidade por restrição, definido pelo quadrado da violação da restrição}}$$

- Define uma sucessão de subproblemas de minimização sem restrições da forma:

$$\underset{w \in \mathbb{R}^I}{\text{minimizar}} \quad Q(w, \mu_k)$$

para uma sucessão crescente dos parâmetros de penalidade μ , com $\mu_k \uparrow \infty$ quando $k \rightarrow \infty$.

- Ao fazer o valor de $\mu_k \uparrow \infty$, penaliza as violações das restrições de forma mais severa, forçando o minimizante de Q a ficar mais próximo da região admissível do problema original (1).

Algoritmo1: Método de Penalidade Quadrática

- 1 Dar: μ_0 , um ponto inicial $w_s^{(0)}$, uma sequência não negativa $\{\tau_k\}$ com $\tau_k \rightarrow 0$
- 2 Para $k = 0, 1, \dots$
- 3 Encontrar um minimizante (aproximado) $w^{(k)}$ de $Q(w; \mu_k)$, iniciando em $w_s^{(k)}$ e parar quando $\|\nabla_w Q(w; \mu_k)\| \leq \tau_k$
- 4 **Se** $w^{(k)}$ satisfaz o critério de paragem final
Parar com a solução (aproximada) $w^{(k)}$
fim se
- 5 Escolher novo parâmetro de penalidade $\mu_{k+1} > \mu_k$
- 6 Escolher novo ponto inicial $w_s^{(k+1)}$
- 7 Escolher nova tolerância $\tau_{k+1} < \tau_k$ (com $\tau_{k+1} > 0$)

(nota: $\nabla_w Q(w; \mu_k) = \nabla_w F(w) + \mu_k \sum_{n \in \mathcal{E}} c_n(w) \nabla_w c_n(w) - \mu_k \sum_{n \in \mathcal{I}} \max(0, -c_n(w)) \nabla_w c_n(w)$)

(nota: se $\mathcal{I} \neq \{\}$, o vetor gradiente não está definido nos pontos w para os quais $c_n(w) = 0$ com $n \in \mathcal{I}$)

Suavidade dos termos de penalidade:

- Restrições de igualdade: os termos c_n^2 são suaves.
 \Rightarrow quando apenas existem restrições de igualdade, podemos usar técnicas baseados em derivadas para otimização sem restrições para encontrar a solução $w^{(k)}$ de $Q(w; \mu_k)$;
- Restrições de desigualdade: os termos $(\max(0, -c_n))^2$ podem ser menos suaves do que c_n .
ex: se uma restrição é $w_1 \geq 0$, então a função $(\max(0, -c_n))^2$ tem uma 2ª derivada descontínua, e portanto Q não é mais duas vezes continuamente diferenciável.
- A minimização de $Q(w; \mu_k)$ torna-se mais difícil de realizar à medida que μ_k aumenta.

Escolha do ponto inicial w_s^k para minimizar $Q(w; \mu_k)$:

- usar um dos minimizantes anteriores de $Q(w; \mu)$: $w^{(k-1)}, w^{(k-2)}, \dots$
("warm start": $w_s^k = w^{(k-1)}$)
- ...

Escolha da sequência $\{\mu_k\}$: adaptativa, por exemplo, se a minimização $Q(w; \mu_k)$ foi de custo computacional:

- elevado: fazer um aumento modesto, por ex., $\mu_{k+1} = 1.5\mu_k$
- baixo: fazer um aumento maior, por ex., $\mu_{k+1} = 10\mu_k$

Escolha da sequência $\{\tau_k\}$: $\tau_k \longrightarrow 0$

(a minimização é realizada progressivamente com mais precisão)

Critério de paragem $\|\nabla_w Q(w; \mu_k)\| \leq \tau_k$:

⇒ não há garantias que seja satisfeito, os iterandos podem afastar-se da região admissível quando o μ_k não é grande o suficiente;

⇒ uma implementação prática, deve incluir salvaguardas que incremente o parâmetro de penalidade (e possivelmente restaure o ponto inicial) quando a violação das restrições não está a decrescer rapidamente o suficiente, ou quando os iterandos parecem ser divergentes.

nota: Para escolhas adequadas de μ_k e do ponto inicial w_s^k , a minimização de $Q(w; \mu_k)$ é efetuada em poucos passos/iterações.

Exercício1: Considere o problema



$$\underset{w \in \mathbb{R}^2}{\text{minimizar}} \quad F(w) = w_1 + w_2 \quad \text{sujeito a} \quad w_1^2 + w_2^2 - 2 = 0$$

cuja solução é $(-1, -1)^T$. Minimize a função de penalidade quadrática $Q(w; \mu)$ do problema, com $\mu = 1$ e $\mu = 10$, usando um algoritmo de otimização sem restrições. Faça os gráficos dos contornos de Q .

(nota: use a função *fminunc* do MatLab para calcular os minimizantes/maximizantes de Q)



Solução: $Q(w; \mu) = w_1 + w_2 + \frac{\mu}{2}(w_1^2 + w_2^2 - 2)^2$

- Para $\mu = 1$, a função Q tem um minimizante no ponto $(-1.1072, -1.1072)^T$ e um maximizante no ponto $(0.2696, 0.2696)^T$.



- Para $\mu = 10$, os pontos que não satisfazem a restrição sofrem uma maior penalização - o “vale” de valores baixos de Q é evidente. A função Q tem um minimizante no ponto $(-1.0123, -1.0123)^T$, que está mais perto da solução $(-1, -1)^T$.

Q tem um maximizante no ponto $(0.025, 0.025)^T$, e Q vai rapidamente para ∞ para pontos fora da circunferência $w_1^2 + w_2^2 = 2$.



A situação nem sempre é tão *favorável* como a reportada no Exercício1. Para um dado valor do parâmetro de penalidade μ , a função de penalidade pode ser ilimitada inferiormente ainda que o problema com restrições original tenha uma única solução. Esta deficiência é, infelizmente, comum a todas as funções de penalidade aqui apresentadas.



Exercício2: Considere o problema

$$\underset{w \in \mathbb{R}^2}{\text{minimizar}} \quad F(w) = -5w_1^2 + w_2^2 \quad \text{sujeito a } w_1 = 1$$



cujas solução é $(1, 0)^T$. Minimize a função de penalidade quadrática $Q(w; \mu)$ do problema, com $\mu = 1$ e $\mu = 100$, usando um algoritmo de otimização sem restrições. Faça os gráficos dos contornos de Q .

Solução: a função de penalidade $Q(w; \mu) = -5w_1^2 + w_2^2 + \frac{\mu}{2}(w_1 - 1)^2$ é ilimitada para qualquer $\mu < 10$.

- Para $\mu = 1 < 10$, a função $Q(w; 1)$ é ilimitada inferiormente. Usando o `fminunc`, o algoritmo pára ao fim de 1ª iteração com `exitflag=-3` 'objective function at current iteration went below ObjectiveLimit'.



- Para $\mu = 100$ e usando o fminunc, o algoritmo pára ao fim de 2ª iteração com `exitflag=1` 'magnitude of gradient is smaller than the *OptimalityTolerance tolerance*', e $Q(w; 10)$ tem um minimizante no ponto $(1.1111, 0)^T$, que está perto da solução $(1, 0)^T$.



Exercício3: Considere novamente o problema

$$\underset{w \in \mathbb{R}^2}{\text{minimizar}} \quad F(w) = w_1 + w_2 \quad \text{sujeito a} \quad w_1^2 + w_2^2 - 2 = 0$$

- a) Minimize a função de penalidade quadrática Q do problema, para $\mu_k = 1, 10, 100, 1000$ usando um algoritmo de otimização sem restrições.
- b) Implemente o Método de Penalidade Quadrática (Algoritmo1) para resolver o problema, com $w^{(0)} = (0, 0)^T$ e $\mu_0 = 1$. Faça $\mu_{k+1} = 10\mu_k$, $\tau_k = 1/\mu_k$ e escolha para ponto inicial $w_s^{(k+1)}$ a solução de $Q(w; \mu_k)$. Para critério de paragem final use as condições:

$$\|c_{\mathcal{E}}(w^{(k)})\|_{\infty} \leq \varepsilon_1 \quad (\text{medida da violação})$$

$$\frac{|F(w^{(k)}) - F(w^{(k-1)})|}{|Fw^{(k)}|} \leq \varepsilon_2, \quad \frac{\|w^{(k)} - w^{(k-1)}\|_{\infty}}{\|w^{(k)}\|_{\infty}} \leq \varepsilon_3$$

com $\varepsilon_1 = 10^{-6}$, $\varepsilon_2 = \varepsilon_3 = 10^{-4}$.

Indique a solução (aproximada) de cada função de penalidade $Q(w; \mu_k)$.

- c) Compare a solução ótima obtida em b) com a solução obtida usando a função `fmincon` do MatLab.

Exercício4: Considere agora o problema

$$\begin{aligned} \underset{w \in \mathbb{R}^2}{\text{minimizar}} \quad & F(w) = \frac{1}{2}w_1^2 + w_2^2 - w_1w_2 - 2w_1 - 6w_2 \\ \text{sujeito a } c(w) = & \begin{cases} -w_1 - w_2 + 2 \geq 0 \\ w_1 - 2w_2 + 2 \geq 0 \\ -2w_1 - w_2 + 3 \geq 0 \\ w_1, w_2 \geq 0 \end{cases} \end{aligned}$$

- a) Utilize o Método de Penalidade Quadrática para resolver o problema, com $w^{(0)} = (0, 0)^T$ e $\mu_0 = 1.5$. Faça $\mu_{k+1} = 2\mu_k$, $\tau_k = 1/\mu_k$ e escolha para ponto inicial $w_s^{(k+1)}$ a solução de $Q(w; \mu_k)$. Para critério de paragem final use as condições:

$$\begin{aligned} \|\max(0, -c_I(w^{(k)}))\|_\infty &\leq \varepsilon_1 \quad (\text{medida da violação}) \\ \frac{|F(w^{(k)}) - F(w^{(k-1)})|}{|Fw^{(k)}|} &\leq \varepsilon_2, \quad \frac{\|w^{(k)} - w^{(k-1)}\|_\infty}{\|w^{(k)}\|_\infty} \leq \varepsilon_3 \end{aligned}$$

com $\varepsilon_1 = 10^{-6}$, $\varepsilon_2 = \varepsilon_3 = 10^{-6}$.

- b) Compare a solução ótima obtida em a) com a solução obtida usando a função `fmincon` do MatLab.

Exercício5: (HS6) Considere o problema

$$\underset{w \in \mathbb{R}^2}{\text{minimizar}} F(w) = (1 - w_1)^2 \text{ sujeito a } 10(w_2 - w_1^2) = 0$$

- a) Utilize o Método de Penalidade Quadrática para resolver o problema, com $w^{(0)} = (-1.2, 1)^T$ e $\mu_0 = 1$. Faça $\mu_{k+1} = 2\mu_k$, $\tau_k = 1/\mu_k$ e escolha para ponto inicial $w_s^{(k+1)}$ a solução de $Q(w; \mu_k)$. Para critério de paragem final use as condições:

$$\|c_{\mathcal{E}}(w^{(k)})\|_{\infty} \leq \varepsilon_1 \quad (\text{medida da violação})$$

$$\frac{|F(w^{(k)}) - F(w^{(k-1)})|}{|F w^{(k)}|} \leq \varepsilon_2, \quad \frac{\|w^{(k)} - w^{(k-1)}\|_{\infty}}{\|w^{(k)}\|_{\infty}} \leq \varepsilon_3$$

com $\varepsilon_1 = 10^{-6}$, $\varepsilon_2 = \varepsilon_3 = 10^{-6}$.

- b) Compare a solução ótima obtida em a) com a solução obtida usando a função `fmincon` do MatLab.

Exercício6: (HS32) Considere o problema

$$\underset{w \in \mathbb{R}^3}{\text{minimizar}} \quad F(w) = (w_1 + 3w_2 + w_3)^2 + 4(w_1 - w_2)^2$$

$$\text{sujeito a} \quad \begin{cases} 6w_2 + 4w_3 - w_1^3 - 3 & \geq 0 \\ 1 - w_1 - w_2 - w_3 & = 0 \\ w_1, w_2, w_3 & \geq 0 \end{cases}$$

- a) Utilize o Método de Penalidade Quadrática para resolver o problema, com $w^{(0)} = (0.1, 0.7, 0.2)^T$ e $\mu_0 = 1.5$. Faça $\mu_{k+1} = 2\mu_k$, $\tau_k = 1/\mu_k$ e escolha para ponto inicial $w_s^{(k+1)}$ a solução de $Q(w; \mu_k)$. Para critério de paragem final use as condições:

$$\|c_{\mathcal{E}}(w^{(k)}), \max(0, -c_{\mathcal{I}}(w^{(k)}))\|_{\infty} \leq \varepsilon_1 \quad (\text{medida da violação})$$

$$\frac{|F(w^{(k)}) - F(w^{(k-1)})|}{|Fw^{(k)}|} \leq \varepsilon_2, \quad \frac{\|w^{(k)} - w^{(k-1)}\|_{\infty}}{\|w^{(k)}\|_{\infty}} \leq \varepsilon_3$$

com $\varepsilon_1 = 10^{-6}$, $\varepsilon_2 = \varepsilon_3 = 10^{-6}$.

- b) Compare a solução ótima obtida em a) com a solução obtida usando a função `fmincon` do MatLab.

Convergência do método de penalidade quadrática

São descritas algumas das propriedades do método em dois teoremas. Será apenas considerado o problema com restrições de igualdade

$$\begin{array}{ll} \underset{w \in \mathbb{R}^1}{\text{minimizar}} & F(w) \\ \text{sujeito a} & c_n(w) = 0, \quad n \in \mathcal{E} \end{array} \quad (2)$$

para o qual a função de penalização quadrática é definida por

$$Q(w; \mu) = F(w) + \frac{\mu}{2} \sum_{n \in \mathcal{E}} (c_n(w))^2 \quad (3)$$

e assume-se que $\mu_k \uparrow \infty$ (i.e., $\mu_{k+1} > \mu_k$ para todo k e $\lim_{k \rightarrow +\infty} \mu_k = +\infty$).

Para o primeiro resultado, assume-se que a função de penalidade $Q(w; \mu_k)$ tem um minimizante global para cada valor de μ_k .

Teorema 1

Suponha que cada $w^{(k)}$ é o *minimizante global exato* de $Q(w; \mu_k)$ em (3) no Algoritmo1, e que $\mu_k \uparrow \infty$. Então todo o ponto limite w^* da sucessão de soluções $\{w^{(k)}\}$, dos respetivos problemas sem restrições $Q(w; \mu_k)$, é uma *solução global do problema com restrições* (2).

(**nota:** em geral, **impraticável** pois exige a minimização global de cada subproblema $Q(w; \mu_k)$ (ou um problema convexo))

Demonstração

Seja \bar{w} a solução global de (2), isto é,

$$F(\bar{w}) \leq F(w) \text{ para todo } w \text{ com } c_n(w) = 0, n \in \mathcal{E}$$

Como $w^{(k)}$ minimiza $Q(w; \mu_k)$ para cada k , tem-se que $Q(w^{(k)}; \mu_k) \leq Q(\bar{w}; \mu_k)$, donde segue a desigualdade

$$F(w^{(k)}) + \frac{\mu_k}{2} \sum_{n \in \mathcal{E}} (c_n(w^{(k)}))^2 \leq F(\bar{w}) + \frac{\mu_k}{2} \sum_{n \in \mathcal{E}} (c_n(\bar{w}))^2 = F(\bar{w}) \quad (4)$$

Reorganizando esta expressão, obtém-se

$$\sum_{n \in \mathcal{E}} (c_n(w^{(k)}))^2 \leq \frac{2}{\mu_k} [F(\bar{w}) - F(w^{(k)})]. \quad (5)$$

Suponha que w^* é o limite da sucessão $\{w^{(k)}\}$, então existe uma subsucessão infinita \mathcal{K} tal com

$$\lim_{k \in \mathcal{K}} w^{(k)} = w^*$$

Fazendo o limite com $k \rightarrow \infty$ para $k \in \mathcal{K}$, em ambos os lados de (5), obtém-se

$$\sum_{n \in \mathcal{E}} (c_n(w^*))^2 = \lim_{k \in \mathcal{K}} \sum_{n \in \mathcal{E}} (c_n(w^{(k)}))^2 \leq \lim_{k \in \mathcal{K}} \frac{2}{\mu_k} [F(\bar{w}) - F(w^{(k)})] = 0$$

onde a última igualdade vem de $\mu_k \uparrow \infty$. Portanto, tem-se que $c_n(w^*) = 0$ para todo $n \in \mathcal{E}$, pelo que w^* é ponto admissível. Além disso, fazendo o limite com $k \rightarrow \infty$ para $k \in \mathcal{K}$ em (4), tem-se pela não negatividade de μ_k e de cada $(c_n(w^{(k)}))^2$ que

$$F(w^*) \leq F(w^*) + \lim_{k \in \mathcal{K}} \frac{\mu_k}{2} \sum_{n \in \mathcal{E}} (c_n(w^{(k)}))^2 \leq F(\bar{w})$$

Como w^* é um ponto admissível cujo valor da função objetivo não é maior do que na solução global \bar{w} , conclui-se que w^* , também, é uma solução global do problema (2).



- O segundo resultado diz respeito às propriedades de convergência da sucessão $\{w^{(k)}\}$ quando são efetuadas minimizações não exatas (mas cada vez mais exatas/precisas) de $Q(w; \mu_k)$.
- Em contraste com o Teorema 1, mostra que a sucessão pode convergir:
 - ▷ para pontos não-admissíveis, ou
 - ▷ para um ponto KKT (um ponto que satisfaz as condições necessárias de 1ª ordem), em vez de um minimizante. Também mostra que as quantidades μ_k $c_n(w^{(k)})$ podem ser usadas como estimativas dos multiplicadores de Lagrange λ_n^* .

Para estabelecer os resultados do Teorema 2, assume-se que o critério de paragem $\|\nabla_w Q(w; \mu_k)\| \leq \tau_k$ é satisfeito para todo k .

Teorema 2

Suponha que as tolerâncias e os parâmetros de penalidade no Algoritmo1 satisfazem $\tau_k \rightarrow 0$ e $\mu_k \uparrow \infty$. Se um ponto limite w^* da sucessão é *não-admissível*, então w^* é um *ponto estacionário* da função $\|c(w)\|^2$. Por outro lado, se um ponto limite w^* da sucessão é um *ponto admissível* e os *gradientes* $\nabla c_n(w^*)$ são *linearmente independentes*, então w^* é um *ponto KKT do problema com restrições (2)*. Para tais pontos, para qualquer subsucessão infinita tal que $\lim_{k \in \mathcal{K}} w^{(k)} = w^*$, tem-se que

$$\lim_{k \in \mathcal{K}} -\mu_k c_n(w^{(k)}) = \lambda_n^*, \quad \text{para todo } n \in \mathcal{E} \quad (6)$$

onde λ^* é o vector dos multiplicadores de Lagrange que satisfazem as condições KKT para o problema com restrições de igualdade (2).

Demonstração

Derivando $Q(w; \mu_k)$ em (3), obtém-se:

$$\nabla_w Q(w^{(k)}; \mu_k) = \nabla F(w^{(k)}) + \sum_{n \in \mathcal{E}} \mu_k c_n(w^{(k)}) \nabla c_n(w^{(k)}). \quad (7)$$

Pelo critério de paragem do Algoritmo1, tem-se que

$$\|\nabla F(w^{(k)}) + \mu_k \sum_{n \in \mathcal{E}} c_n(w^{(k)}) \nabla c_n(w^{(k)})\| \leq \tau_k. \quad (8)$$

Usando a desigualdade $\|a\| - \|b\| \leq \|a + b\|$, obtém-se

$$\begin{aligned} \mu_k \left\| \sum_{n \in \mathcal{E}} c_n(w^{(k)}) \nabla c_n(w^{(k)}) \right\| - \|\nabla F(w^{(k)})\| &\leq \tau_k \Leftrightarrow \\ \left\| \sum_{n \in \mathcal{E}} c_n(w^{(k)}) \nabla c_n(w^{(k)}) \right\| &\leq \frac{1}{\mu_k} [\tau_k + \|\nabla F(w^{(k)})\|]. \end{aligned} \quad (9)$$

Seja w^* um ponto limite da sucessão $\{w^{(k)}\}$.

Então existe uma subsucessão \mathcal{K} tal que $\lim_{k \in \mathcal{K}} w^{(k)} = w^*$.

Fazendo o limite com $k \rightarrow \infty$ para $k \in \mathcal{K}$, em ambos os lados de (9), o termo dentro do parêntesis do lado direito aproxima-se de $\|\nabla F(w^*)\|$. Como $\mu_k \uparrow \infty$, o lado direito aproxima-se de zero. Considerando o limite no lado esquerdo, obtém-se:

$$\sum_{n \in \mathcal{E}} c_n(w^*) \nabla c_n(w^*) = 0. \quad (10)$$

Podemos ter $c_n(w^*) \neq 0$ se os gradientes das restrições $\nabla c_n(w^*)$ são linearmente dependentes em w^* . Neste caso (10) implica que w^* é um ponto estacionário da função $\|c(w)\|^2$.

Se, por outro lado, os gradientes das restrições $\nabla c_n(w^*)$ são linearmente independentes, tem-se de (10) que $c_n(w^*) = 0$ para todo $n \in \mathcal{E}$, portanto w^* é um ponto admissível. Logo, a 2ª condição das condições KKT (condição de admissibilidade) é satisfeita. É necessário verificar também a 1ª condição KKT e mostrar que o limite (6) é válido.

Denotando por $A(w)$ a matriz dos gradientes das restrições

$$A(w)^T = [\nabla c_n]_{n \in \mathcal{E}},$$

e denotando por $\lambda^{(k)}$ o vetor $-\mu_k c(w^{(k)})$, tem-se por (7) e (8) que

$$A(w^{(k)})^T \lambda^{(k)} = \nabla F(w^{(k)}) - \nabla_w Q(w^{(k)}; \mu_k), \quad \|\nabla_w Q(w^{(k)}; \mu_k)\| \leq \tau_k. \quad (11)$$

Para todo $k \in \mathcal{K}$ suficientemente grande, a matriz $A(w^{(k)})$ tem característica completa por linhas, assim $A(w^{(k)})A(w^{(k)})^T$ é não singular. Multiplicando (11) por $A(w^{(k)})$ e reorganizando obtém-se:

$$\lambda^{(k)} = \left[A(w^{(k)})A(w^{(k)})^T \right]^{-1} A(w^{(k)}) \left[\nabla F(w^{(k)}) - \nabla_w Q(w^{(k)}; \mu_k) \right]$$

Portanto, fazendo o limite $k \rightarrow \infty$ para $k \in \mathcal{K}$, obtém-se

$$\lim_{k \in \mathcal{K}} \lambda^{(k)} = \lambda^* = \left[A(w^*)A(w^*)^T \right]^{-1} A(w^*) \nabla F(w^*).$$

Fazendo o limite em (8), conclui-se que

$$\nabla F(w^*) - A(w^*)^T \lambda^* = 0,$$

assim λ^* satisfaz a 1ª condição KKT para o problema (2). Portanto, w^* é um ponto KKT para o problema (2), com único vetor de multiplicadores de Lagrange λ^* . □

Comportamento da matriz Hessiana do método de penalidade quadrática

- Vamos agora analisar a natureza do mau-condicionamento na matriz Hessiana $\nabla_{ww}^2 Q(w; \mu_k)$.
- A compreensão das propriedades desta matriz, e das Hessianas semelhantes que surgem noutros métodos de penalização e de barreira, é importante para escolher algoritmos eficazes para o problema de minimização e para os cálculos de álgebra linear em cada iteração.

Considere apenas o problema com restrições de igualdade (2). A matriz Hessiana da função de penalidade quadrática é dada por:

$$\nabla_{ww}^2 Q(w; \mu_k) = \nabla^2 F(w^*) + \sum_{n \in \mathcal{E}} \mu_k c_n(w) \nabla^2 c_n(w) + \mu_k A(w)^T A(w)$$

nota:

- $A(w)^T = [\nabla c_n(w)]_{I \times |\mathcal{E}|}$ é a matriz dos gradientes das restrições (conhecida por matriz do Jacobiano; geralmente $\text{rank}(A) = |\mathcal{E}| < I$);

Quando w está próximo de um minimizante de $Q(\cdot; \mu_k)$, e as condições do Teorema 2 são satisfeitas, tem-se que $\mu_k c_n(w) \approx -\lambda_n^*$ e portanto

$$\begin{aligned} \nabla_{ww}^2 Q(w; \mu_k) &\approx \nabla^2 F(w^*) - \sum_{n \in \mathcal{E}} \lambda_n^* \nabla^2 c_n(w) + \mu_k A(w)^T A(w) \\ &\approx \underbrace{\nabla_{ww}^2 L(w, \lambda^*)}_{\text{independente de } \mu_k} + \underbrace{\mu_k A(w)^T A(w)}_{\text{rank } |\mathcal{E}| \text{ com } \textit{eigenvalues} \text{ não nulos da ordem } \mu_k} \end{aligned}$$

- Em geral como o número de restrições $|\mathcal{E}| < I$, $A(w)^T A(w)$ é singular.
- A matriz $\nabla_{ww}^2 Q(w; \mu_k)$ tem alguns dos seus *eigenvalues* que se aproximam de uma constante, enquanto outros são da ordem μ_k .
- Como $\mu_k \uparrow \infty$, o crescente mau-condicionamento da matriz $\nabla_{ww}^2 Q(w; \mu_k)$ é evidente.
- Os métodos de otimização sem restrições (de 1^ª e 2^ª ordem) tem problemas com o mau-condicionamento, a menos que sejam acompanhados por uma estratégia de pré-condicionamento que elimine o mau-condicionamento sistemático.
- **nota:** $L(w, \lambda) = F(w) - \sum_{n \in \mathcal{E}} \lambda_n c_n(w)$ é a função Lagrangeana.

Uma consequência do mau-condicionamento é os possíveis erros ao aplicar o método de Newton para calcular a direção de procura s para minimizar $Q(w; k)$, que se obtém resolvendo o seguinte sistema:

$$\nabla_{ww}^2 Q(w; \mu_k) s = -\nabla_w Q(w; \mu_k)$$

Em geral, o mau-condicionamento da matriz Hessiana conduz a erros significativos no cálculo do valor de s , independentemente da técnica computacional utilizada para encontrar a solução deste sistema.