

Métodos de Penalidade

Métodos de Penalidade Exata Não Suaves

M. Fernanda P. Costa

Departamento de Matemática
Universidade do Minho

- 1 Métodos de Penalidade
 - Métodos de Penalidade Exata Não Suaves
 - Classe Geral de Métodos de Penalidade Exata Não Suaves

Considere novamente a formulação geral do problema de otimização com restrições:

$$\begin{array}{ll} \underset{w \in \mathbb{R}^I}{\text{minimizar}} & F(w) \\ \text{sujeito a} & c_n(w) = 0, \quad n \in \mathcal{E} \\ & c_n(w) \geq 0, \quad n \in \mathcal{I} \end{array} \quad (\text{P1})$$

- $w = (w_1, w_2, \dots, w_I)^T$ é o vetor das variáveis de decisão
- $F : \mathbb{R}^I \rightarrow \mathbb{R}$ é a função objetivo (medida de desempenho)
(loss or cost function in ML)
- $c_n : \mathbb{R}^I \rightarrow \mathbb{R}$ com $n \in \mathcal{E}$, são as funções de restrição de igualdade
- $c_n : \mathbb{R}^I \rightarrow \mathbb{R}$ com $n \in \mathcal{I}$, são as funções de restrição de desigualdade
- **nota:** em (P1) as funções de restrição $c_n(w)$, para $n \in \mathcal{E}$ e $n \in \mathcal{I}$, podem ser agrupadas nas funções vetoriais $c_{\mathcal{E}} : \mathbb{R}^I \rightarrow \mathbb{R}^{|\mathcal{E}|}$ e $c_{\mathcal{I}} : \mathbb{R}^I \rightarrow \mathbb{R}^{|\mathcal{I}|}$:

$$\begin{aligned} c_{\mathcal{E}}(w) &= 0 \\ c_{\mathcal{I}}(w) &\geq 0 \end{aligned}$$

Funções de Penalidade Exatas Não Suaves

- Algumas **funções de penalidade** $\phi(w; \mu)$ são **exatas**, isto é, para certas escolhas dos parâmetros de penalidade ($\exists \mu^* > 0 : \forall \mu > \mu^*$), qualquer solução local w^* do problema com restrições é um **minimizante local da função de penalidade** $\phi(w; \mu)$.
- Assim, precisamos de uma única minimização de $\phi(w; \mu)$ para um tal $\mu > \mu^*$, para obter a solução exata do problema com restrições.
- Esta propriedade é desejável, pois faz com que o desempenho dos métodos de penalidade sejam menos dependentes da estratégia de atualização do parâmetro de penalidade.

nota: a função de penalidade quadrática $Q(w; \mu)$ não é exata, por isso precisa $\mu \uparrow \infty$.

Uma **função de penalidade exata não suave** muito usada para o problema com restrições (P1) é a **função de penalidade ℓ_1** , definida por:

$$\phi_1(w; \mu) = \underbrace{F(w)}_{\text{função objetivo}} + \underbrace{\mu \sum_{n \in \mathcal{E}} |c_n(w)| + \mu \sum_{n \in \mathcal{I}} [\max(0, -c_n(w))]}_{\text{um termo de penalidade por restrição, definido pelo valor absoluto da violação da restrição}}$$

- O nome deriva do facto que o termo de penalidade é μ vezes a norma ℓ_1 da violação da restrição. (nota: norma $\|\cdot\|_1$ é também conhecida como norma ℓ_1)
- Notar que $\phi_1(w; \mu)$ não é diferenciável em alguns pontos w , devido à presença das funções $|\cdot|$ e $\max(0, -c_{\mathcal{I}}(w))$.

O resultado seguinte estabelece a exatidão da função de penalidade ℓ_1 .

Teorema 1

Suponha que w^* é uma *solução local estrita do problema com restrições (P1)* para o qual as condições necessárias de 1ª ordem são satisfeitas (condições KKT), com multiplicadores de Lagrange λ_n^* , $n \in \mathcal{E} \cup \mathcal{I}$. Então w^* é um *minimizante local de $\phi_1(w; \mu)$* para todo $\mu > \mu^*$, onde

$$\mu^* = \|\lambda^*\|_\infty = \max_{n \in \mathcal{E} \cup \mathcal{I}} |\lambda_n^*| \quad (1)$$

Se, adicionalmente, as condições suficientes de 2ª ordem são satisfeitas e $\mu > \mu^*$, então w^* é um *minimizante local estrito de $\phi_1(w; \mu)$* .

Demonstração: (ver [1], Teorema 4.4)

- Em geral, numa solução w^* do problema com restrições (P1), qualquer movimento para a região não admissível é penalizado de forma suficientemente acentuada produzindo um aumento no valor da função de penalidade superior ao valor de $\phi_1(w^*; \mu) = F(w^*)$, forçando assim o minimizante de $\phi_1(w; \mu)$ a ficar em w^* .

Exercício1: Considere o problema

$$\underset{w \in \mathbb{R}}{\text{minimizar}} \quad F(w) = w \quad \text{sujeito a } w \geq 1$$

cuja solução é $w^* = 1$. Indique para que valores de μ , a solução $w^* = 1$ é um minimizante da função de penalidade ℓ_1 .

Solução: A função de penalidade ℓ_1 é

$$\phi_1(w; \mu) = w + \mu \max(0, -(w - 1)) = \begin{cases} (1 - \mu)w + \mu & \text{se } w < 1 \\ w & \text{se } w \geq 1 \end{cases}$$

- se $1 - \mu < 0 \Leftrightarrow \mu > 1$, então ϕ_1 é monótona decrescente para $w < 1$; e crescente para $w \geq 1$, pelo que ϕ_1 tem um minimizante em $w^* = 1$.
- se $1 - \mu > 0 \Leftrightarrow \mu < 1$, então ϕ_1 é monótona crescente para todo $w \in \mathbb{R}$.





Fig.3 função de penalidade ϕ_1 com $\mu > 1$ (esq.) e $\mu < 1$ (dir.)

- Como os métodos de penalidade visam minimizar a função de penalidade, é necessário caracterizar os pontos estacionários desta função. Apesar de ϕ_1 não ser diferenciável, tem derivada direcional ao longo de qualquer direção s , denotada por $\mathcal{D}(\phi_1(w; \mu); s)$
- Definição:** A derivada direcional de uma função $F : \mathbb{R}^I \rightarrow \mathbb{R}$ na direção de s é dada por:

$$\mathcal{D}(F(w); s) = \lim_{\varepsilon \rightarrow 0} \frac{F(w + \varepsilon s) - F(w)}{\varepsilon}.$$

Notar que, a $\mathcal{D}(F(w); s)$ pode estar bem definida mesmo quando F não é continuamente diferenciável.

Quando F é de facto continuamente diferenciável numa vizinha de w , tem-se: $\mathcal{D}(F(w); s) = \nabla F(w)^T s$.

Definição: Um ponto $\hat{w} \in \mathbb{R}^I$ é um ponto estacionário para a função de penalidade $\phi_1(w; \mu)$ se

$$\mathcal{D}(\phi_1(\hat{w}; \mu); s) \geq 0, \text{ para todo } s \in \mathbb{R}^I$$

Do mesmo modo, \hat{w} é um ponto estacionário da *medida de não admissibilidade*

$$h(w) = \sum_{n \in \mathcal{E}} |c_n(w)| + \sum_{n \in \mathcal{I}} [\max(0, -c_n(w))] \quad (\text{medida de violação})$$

se $D(h(\hat{w}); s) \geq 0$ para todo $s \in \mathbb{R}^I$. Se um ponto é não admissível para o problema (P1) mas estacionário em relação à medida de não admissibilidade h , dizemos que é um ponto estacionário não admissível.

Exercício2: Considere novamente o problema

$$\underset{w \in \mathbb{R}}{\text{minimizar}} \quad F(w) = w \quad \text{sujeito a } w \geq 1$$

cuja solução é $w^* = 1$. Calcule a derivada direcional da função $\phi_1(w; \mu)$ no ponto $w^* = 1$.

Solução: Sabemos que

$$\phi_1(w; \mu) = w + \mu \max(0, -(w - 1)) = \begin{cases} (1 - \mu)w + \mu & \text{se } w < 1 \\ w & \text{se } w \geq 1 \end{cases}$$

A derivada direcional de $\phi_1(w; \mu)$ no ponto $w^* = 1$ é:

$$\begin{aligned} D(\phi_1(1; \mu); s) &= \lim_{\varepsilon \rightarrow 0} \frac{\phi_1(1 + \varepsilon s; \mu) - \phi_1(1; \mu)}{\varepsilon} = \\ &= \lim_{\varepsilon \rightarrow 0} \begin{cases} \frac{1 + \varepsilon s - 1}{\varepsilon} & \text{se } s \geq 0 \\ \frac{(1 - \mu)(1 + \varepsilon s) + \mu - 1}{\varepsilon} & \text{se } s < 0 \end{cases} \\ &= \lim_{\varepsilon \rightarrow 0} \begin{cases} s & \text{se } s \geq 0 \\ \frac{(1 - \mu)\varepsilon s}{\varepsilon} & \text{se } s < 0 \end{cases} = \begin{cases} s & \text{se } s \geq 0 \\ (1 - \mu)s & \text{se } s < 0 \end{cases} \end{aligned}$$

donde se conclui que quando $1 - \mu < 0 \Leftrightarrow \mu > 1$, $D(\phi_1(w^*; \mu); s) \geq 0$ para todo $s \in \mathbb{R}$. Portanto, $w^* = 1$ é um ponto estacionário da função $\phi_1(w; \mu)$ com $\mu > 1$.

- O resultado seguinte complementa o Teorema 1, mostrando que os pontos estacionários de $\phi_1(w; \mu)$ correspondem a pontos KKT do problema com restrições (P1) sob certos pressupostos.

Teorema 2

Suponha que \hat{w} é um *ponto estacionário da função de penalidade* $\phi_1(w; \mu)$ para todo μ maior que um certo valor limiar $\hat{\mu} > 0$. Se \hat{w} é *ponto admissível para o problema com restrições (P1)*, então *satisfaz as condições de KKT para (P1)*. Se \hat{w} não é admissível para (P1), é um *ponto estacionário não admissível*.

Demonstração: (ver [2], Teorema 17.4)

Exercício3: Considere novamente o problema

$$\underset{w \in \mathbb{R}^2}{\text{minimizar}} \quad F(w) = w_1 + w_2 \quad \text{sujeito a} \quad w_1^2 + w_2^2 - 2 = 0$$

cuja solução é $w^* = (-1, -1)^T$. Indique para que valores de μ , a solução w^* é um minimizante da função de penalidade ℓ_1 .

Solução: A função de penalidade ℓ_1 do problema é

$$\phi_1(w; \mu) = w_1 + w_2 + \mu |w_1^2 + w_2^2 - 2|.$$

Pelo Teorema 1 temos que para todo $\mu > |\lambda^*| = 0.5$, o minimizante de $\phi_1(w; \mu)$ coincide com w^* . A Fig.4 mostra os contornos de $\phi_1(w; \mu)$ para $\mu = 2$. Os cantos pontiagudos nos contornos indicam a não de suavidade da função $\phi_1(w; 2)$ ao longo da fronteira do círculo definido por $w_1^2 + w_2^2 = 2$.

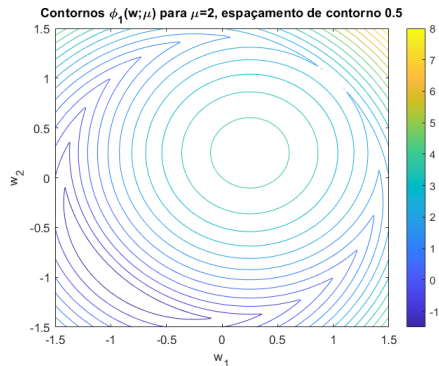



Fig.4 função de penalidade ℓ_1 para $\mu = 2$

Algoritmo2: Método de Penalidade ℓ_1

- Dar: μ_0 , tolerância τ , um ponto inicial $w_s^{(0)}$
- Para $k = 0, 1, \dots$
 - 1 Encontrar um minimizante (aproximado) $w^{(k)}$ de $\phi_1(w; \mu_k)$, iniciando em $w_s^{(k)}$
 - 2 Se $h(w^{(k)}) \leq \tau$
Parar com a solução aproximada $w^{(k)}$
fim se
 - 3 Escolher novo parâmetro de penalidade $\mu_{k+1} > \mu_k$
 - 4 Escolher novo ponto inicial $w_s^{(k+1)}$

Notas:

- A minimização de $\phi_1(w; \mu_k)$ é dificultada pela não suavidade da função.
 \Rightarrow usar métodos de otimização livres de derivadas; ou
 \Rightarrow construir um modelo suave de $\phi_1(w; \mu_k)$ e minimizar este modelo, de um modo análogo ao que se faz nos métodos Programação Quadrática Sequencial (ver [2]).
- **Escolha de μ_k :** a fórmula de atualização mais simples é aumentar μ num valor constante a : $\mu_{k+1} = a\mu_k$ (por ex. $a = 5$ ou 10)

Em geral, esta fórmula de atualização funciona bem na prática mas também pode ser ineficiente:

\Rightarrow se o valor de μ_0 for demasiado pequeno, podem ser necessários muitos ciclos do Algoritmo2 para se encontrar uma solução (aproximada);

\Rightarrow se, por outro lado, μ_k é excessivamente grande, a função de penalidade será difícil de minimização, exigindo possivelmente um grande número de iterações.

Exercício4: Considere novamente o problema

$$\begin{aligned} \underset{w \in \mathbb{R}^2}{\text{minimizar}} \quad & F(w) = \frac{1}{2}w_1^2 + w_2^2 - w_1w_2 - 2w_1 - 6w_2 \\ \text{sujeito a } c(w) = & \begin{cases} -w_1 - w_2 + 2 \geq 0 \\ w_1 - 2w_2 + 2 \geq 0 \\ -2w_1 - w_2 + 3 \geq 0 \\ w_1 \geq 0 \\ w_2 \geq 0 \end{cases} \end{aligned}$$

- a) Utilize o Método de Penalidade ℓ_1 para resolver o problema, com $w^{(0)} = (0, 0)^T$ e $\mu_0 = 1.5$. Faça $\mu_{k+1} = 2\mu_k$, $\tau = 10^{-6}$, e escolha para ponto inicial $w_s^{(k+1)}$ a solução de $\phi_1(w; \mu_k)$. Use a função `fminsearch` do MatLab para resolver os problemas sem restrições.
- b) Compare a solução ótima obtida em a) com a solução obtida usando a função `fmincon` do MatLab.

Exercício5: (HS6) Considere o problema

$$\underset{w \in \mathbb{R}^2}{\text{minimizar}} F(w) = (1 - w_1)^2 \text{ sujeito a } 10(w_2 - w_1^2) = 0$$

- a) Utilize o Método de Penalidade ℓ_1 para resolver o problema, com $w^{(0)} = (-1.2, 1)^T$ e $\mu_0 = 1$. Faça $\mu_{k+1} = 10\mu_k$, $\tau = 10^{-6}$, e escolha para ponto inicial $w_s^{(k+1)}$ a solução de $\phi_1(w; \mu_k)$. Use a função `fminsearch` do MatLab para resolver os problemas sem restrições.
- b) Compare a solução ótima obtida em a) com a solução obtida usando a função `fmincon` do MatLab.

Exercício6: (HS32) Considere o problema

$$\begin{aligned} & \underset{w \in \mathbb{R}^3}{\text{minimizar}} \quad F(w) = (w_1 + 3w_2 + w_3)^2 + 4(w_1 - w_2)^2 \\ & \text{sujeito a} \quad \begin{cases} 6w_2 + 4w_3 - w_1^3 - 3 & \geq 0 \\ 1 - w_1 - w_2 - w_3 & = 0 \\ w_1, w_2, w_3 & \geq 0 \end{cases} \end{aligned}$$

- a) Utilize o Método de Penalidade ℓ_1 para resolver o problema, com $w^{(0)} = (0.1, 0.7, 0.2)^T$ e $\mu_0 = 1.5$. Faça $\mu_{k+1} = 2\mu_k$, $\tau = 10^{-6}$, e escolha para ponto inicial $w_s^{(k+1)}$ a solução de $\phi_1(w; \mu_k)$. Use a função `fminsearch` do MatLab para resolver os problemas sem restrições.
- b) Compare a solução ótima obtida em a) com a solução obtida usando a função `fmincon` do MatLab.

Uma Classe Geral de Métodos de Penalidade Exata Não Suaves

As **funções de penalidade exatas não suaves** podem ser definidas em termos de outras normas que não a norma ℓ_1 :

$$\phi(w, \mu) = F(w) + \mu \|c_{\mathcal{E}}\| + \mu \|\max(0, -c_{\mathcal{I}})\| \quad (2)$$

- $\|\cdot\|$ é uma **norma vetorial qualquer**;
- todas as funções de restrição de igualdade e desigualdade foram agrupadas nas funções vetoriais $c_{\mathcal{E}} : \mathbb{R}^I \rightarrow \mathbb{R}^{|\mathcal{E}|}$ e $c_{\mathcal{I}} : \mathbb{R}^I \rightarrow \mathbb{R}^{|\mathcal{I}|}$.
- O Algoritmo2 aplica-se a qualquer uma destas funções $\phi(w; \mu)$ com a medida de não admissibilidade h definida por

$$h(w) = \|c_{\mathcal{E}}\| + \|\max(0, -c_{\mathcal{I}})\|.$$

- As normas mais usadas na prática são as normas ℓ_1 , ℓ_∞ e ℓ_2 (não ao quadrado).
- As propriedades teóricas descritas para a função ℓ_1 estendem-se para a classe geral (2). No Teorema 1, substitui-se a igualdade (1) por

$$\mu^* = \|\lambda^*\|_D$$

onde $\|\cdot\|_D$ é a norma dual de $\|\cdot\|$

(nota: qualquer norma $\|\cdot\|_p$ tem uma normal dual definida por $\|x\|_D = \max_{\|y\|_p=1} x^T y$.)

As normas ℓ_1 e ℓ_∞ são duais uma da outra; e a norma ℓ_2 é o seu própria dual.)

- O Teorema 2 aplica-se sem modificação.

(nota: As funções de penalidade não suaves são também usadas como *funções mérito* em métodos de otimização que calculam os passos/(direções de procura) por outros mecanismos.)

Exercício7: Resolve os Exercícios 4a), 5a) e 6a) usando a função de penalidade ℓ_∞ , no Algoritmo2.

Exercício8: Resolve os Exercícios 4a), 5a) e 6a) usando a função de penalidade ℓ_2 , no Algoritmo2.



S. P. Han and O. L. Mangasarian.

Exact penalty functions in nonlinear programming.

Mathematical Programming, 17, 1979.



J. Nocedal and S. Wright.

Numerical Optimization.

Springer, 2006.